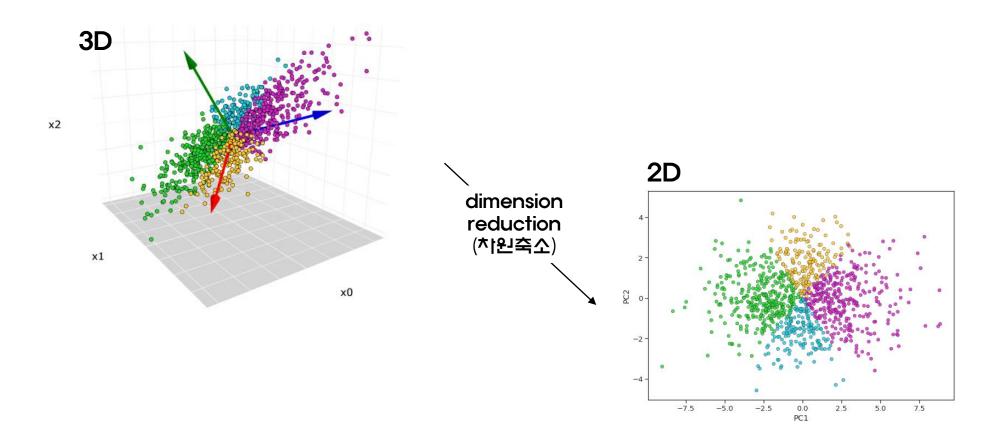
PCA(주성분분석, Principal Component Analysis)



차원 축소 의미

■ 75%의 이미지를 제거해도 수자를 인식할 수 있음







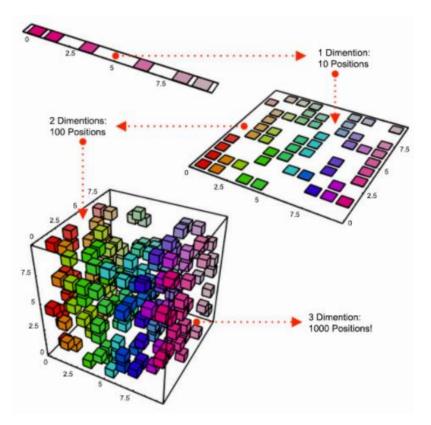
https://towardsdatascience.com/

- Why Feature selection?
 - Memory
 - Time
 - Accuracy
 - Interpretability
 - Debugging



The curse of dimensionality

■ 차원의 저주: 데이터의 차원이 높아질 수록 알고리즘의 실행이 아주 까다로워지는 일



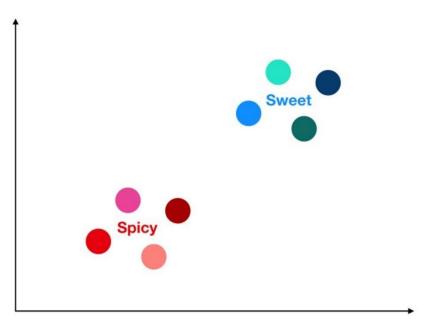
segment, square, cube (1D to 3D cubes)

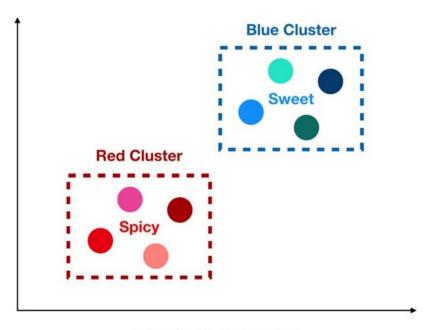
http://www.infme.com/curse-of-dimensionality-ml-big-data-ml-optimization-pca/



The curse of dimensionality

2차원 변수, 8개 instances의 데이터에 대한 군집(Clustering)





Our Two Candy Clusters

Our 2 Color Based Clusters of Candy Flavor



High cardinality

- 8차원 변수, 8개 instances의 데이터에 대한 군집(Clustering)에 문제 발생
 - 일반화(Generalization)이 아닌 memorization
 - 극단적 과적합(Overfitting) 발생, 과거 데이터에 너무 관심을 두고 학습

Reddish	Bluish
1	0
1	0
1	0
1	0
0	1
0	1
0	1
0	1

Perfect Clusters

Red	Maroon	Pink	Flamingo	Blue	Turquoise	Seaweed	Ocean
1	0	0	0	0	0	0	0
0	1	0	0	0	0	0	0
0	0	1	0	0	0	0	0
0	0	0	1	0	0	0	0
0	0	0	0	1	0	0	0
0	0	0	0	0	1	0	0
0	0	0	0	0	0	1	0
0	0	0	0	0	0	0	1

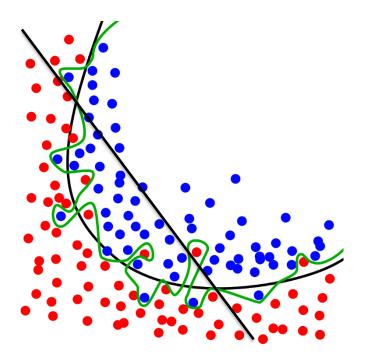
High Dimensional Data Makes Trouble For Clustering

https://towardsdatascience.com/



과적합(Overfitting), Regularization(penalty)

- 다항식 함수가 완벽하게 적합하더라도 선형 함수가 더 잘 일반화된 것
- 두 함수를 사용하여 예측을 하게되면 선형 함수가 더 나은 예측을 하게 됨



15 10 5 0 -5 -10 -15 -6 -4 -2 0 2 4 6

https://en.wikipedia.org/wiki/Overfitting



차원 축소의 방법

projection (선형)

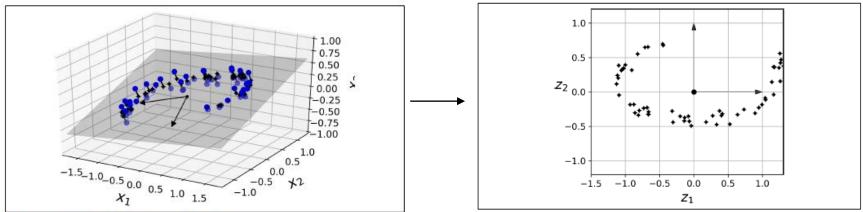


Figure 8-2. A 3D dataset lying close to a 2D subspace

Figure 8-3. The new 2D dataset after projection

manifold (비선형)

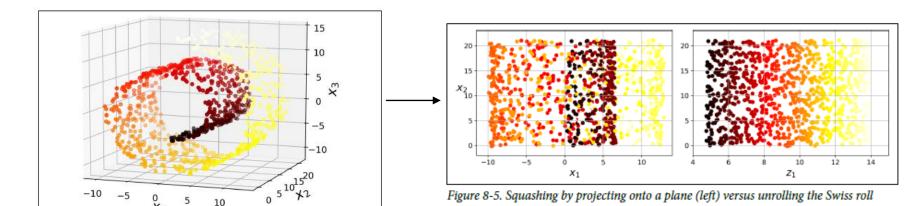


Figure 8-4. Swiss roll dataset

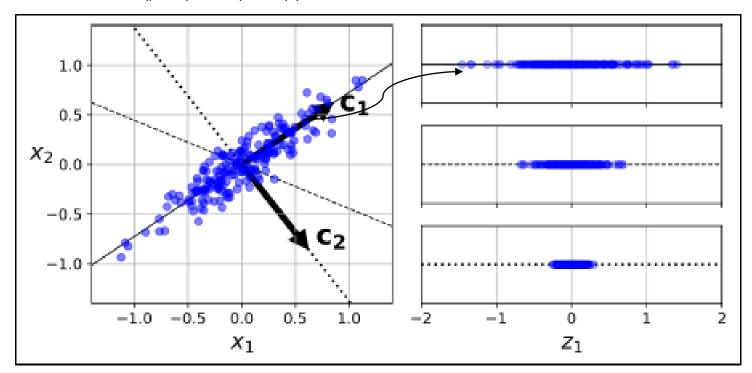
Hands-on Machine Learning-with-Scikit-Learn, Keras & TensorFlow

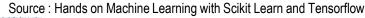
(right)



PCA_총변동의 보존

- 주성분(principal components)
 - 총변동의 대부분을 설명하는 소수의 새로운 변수 (C2 벡터)
 - ✓ The projection of dataset onto three axes.
 - ✓ The Solid line(principal component) preserves the maximum variance.







PCA represented by Matrix

• n 개의 관측치, k개의 변수를 아래 $n \times k$ 행렬로 표현

$$X = \begin{bmatrix} X_{11} & X_{12} & \dots & X_{1k} \\ X_{21} & X_{22} & \dots & X_{2k} \\ \vdots & \vdots & \vdots & \vdots \\ X_{n1} & X_{n2} & \dots & X_{nk} \end{bmatrix} = (X_1, X_2, \dots, X_k)$$

(Mean centering)

평균 조정된 X =
$$\begin{bmatrix} X_{11} - \overline{X_1} & X_{12} - \overline{X_2} & \dots & X_{1k} - \overline{X_k} \\ X_{21} - \overline{X_1} & X_{22} - \overline{X_2} & \dots & X_{2k} - \overline{X_k} \\ \vdots & \vdots & \dots & \vdots \\ X_{n1} - \overline{X_1} & X_{n2} - \overline{X_2} & \dots & X_{nk} - \overline{X_k} \end{bmatrix}$$

(Standardizing)

표준화된
$$X = \begin{bmatrix} \frac{X_{11} - \overline{X_1}}{S_1} & \frac{X_{12} - \overline{X_2}}{S_2} & & \frac{X_{11} - \overline{X_k}}{S_k} \\ \frac{X_{21} - \overline{X_1}}{S_1} & \frac{X_{22} - \overline{X_2}}{S_2} & & \frac{X_{21} - \overline{X_k}}{S_k} \\ \vdots & \vdots & & \vdots \\ \frac{X_{n1} - \overline{X_1}}{S_1} & \frac{X_{n2} - \overline{X_2}}{S_2} & & \frac{X_{n1} - \overline{X_k}}{S_k} \end{bmatrix}$$

PCA_총변동

$$X = (X_1, X_2, X_3) = \begin{bmatrix} 2 & 3 & 11 \\ 3 & 5 & 8 \\ 4 & 7 & 5 \\ 3 & 5 & 8 \end{bmatrix} \qquad \text{For all } Z \neq X \neq X = \begin{bmatrix} -1 & -2 & 3 \\ 0 & 0 & 0 \\ 1 & 2 & -3 \\ 0 & 0 & 0 \end{bmatrix}$$

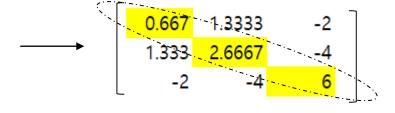
 $\overline{X} = (3, 5, 8)$ $\overline{X_1}$ $\overline{X_2}$

평균조정된
$$X = \begin{bmatrix} -1 & -2 & 3 \\ 0 & 0 & 0 \\ 1 & 2 & -3 \\ 0 & 0 & 0 \end{bmatrix}$$

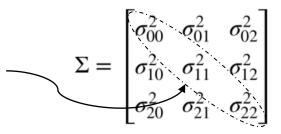
평균조정된X * transpose(평균조정된X)

$$\begin{bmatrix} -1 & 0 & 1 & 0 \\ -2 & 0 & 2 & 0 \\ 3 & 0 & -3 & 0 \end{bmatrix} \times \begin{bmatrix} -1 & -2 & 3 \\ 0 & 0 & 0 \\ 1 & 2 & -3 \\ 0 & 0 & 0 \end{bmatrix}$$

표본 공분산



총변동은 trace (trans(X)*X로 방행 렬의 대각선 원소의합



PCA as geometry

$$A = egin{bmatrix} 2 & 1 \ 1 & 2 \end{bmatrix}$$
 .

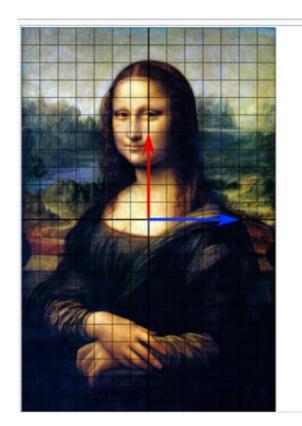
$$|A-\lambda I| = egin{bmatrix} 2 & 1 \ 1 & 2 \end{bmatrix} - \lambda egin{bmatrix} 1 & 0 \ 0 & 1 \end{bmatrix} = egin{bmatrix} 2 - \lambda & 1 \ 1 & 2 - \lambda \end{bmatrix}$$
 $= 3 - 4\lambda + \lambda^2.$

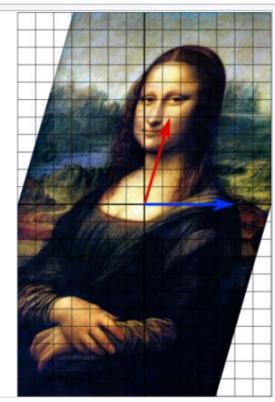
$$\mathbf{v}_{\lambda=1} = \left[egin{array}{c} v_1 \ -v_1 \end{array}
ight] = \left[egin{array}{c} 1 \ -1 \end{array}
ight]$$

$$\mathbf{v}_{\lambda=3}=egin{bmatrix} v_1 \ v_1 \end{bmatrix}=egin{bmatrix} 1 \ 1 \end{bmatrix}$$

$$\mathbf{A}\mathbf{v}=\lambda\mathbf{v}$$

$$(\mathbf{A} - \lambda_i \mathbf{I}) \mathbf{v} = 0.$$

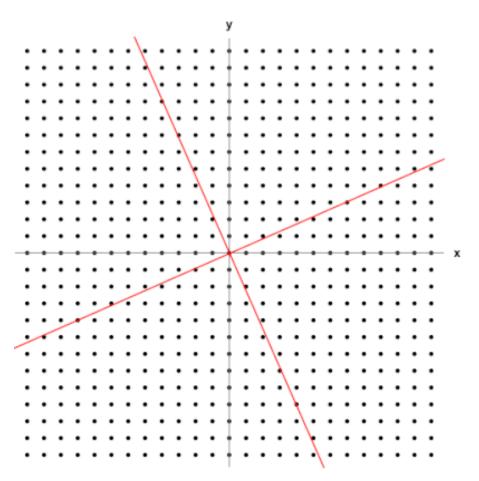




https://en.wikipedia.org/wiki/Eigenvalues_and_eigenvectors

PCA as geometry

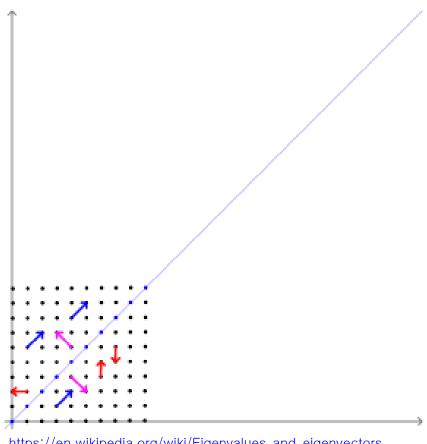
Matrix A does not acts eigenvectors.





PCA as geometry

Matrix A does not acts eigenvectors.







주성분의 의미

0123456789 0123456783 0123456783

Source: Python Datascience Handbook

```
1 digits.data.shape
2 digits.data[0]
3 digits.data
(1797. 64)
```

```
array([ 0., 0., 5., 13., 9., 1., 0., 0., 0., 0., 13., 15., 10., 15., 5., 0., 0., 3., 15., 2., 0., 11., 8., 0., 0., 4., 12., 0., 0., 8., 8., 0., 0., 5., 8., 0., 0., 9., 8., 0., 0., 4., 11., 0., 1., 12., 7., 0., 0., 2., 14., 5., 10., 12., 0., 0., 0., 0., 0., 6., 13., 10., 0., 0., 0.])
```

```
array([[ 0., 0., 5., ..., 0., 0., 0.], [ 0., 0., 0., ..., 10., 0., 0.], [ 0., 0., 0., 0., 16., 9., 0.], ..., [ 0., 0., 1., ..., 6., 0., 0.], [ 0., 0., 2., ..., 12., 0., 0.], [ 0., 0., 10., ..., 12., 1., 0.]])
```

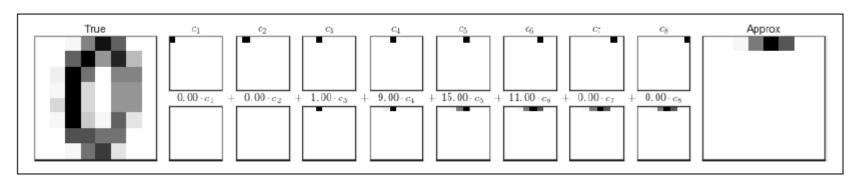
- 이미지 훈련데이터를 64개의 pixel(변수)로 나타내는 벡터(vector, x)로 가정 $x = [x_1, x_2, x_3 \cdots x_{64}]$
- 64개 차원의 기저(basis)를 갖는 함수로 개별 이미지를 선형결합으로 표현

$$\mathrm{image}(x) = x_1 \cdot (\mathrm{pixel\ 1}) + x_2 \cdot (\mathrm{pixel\ 2}) + x_3 \cdot (\mathrm{pixel\ 3}) \cdots x_{64} \cdot (\mathrm{pixel\ 64})$$



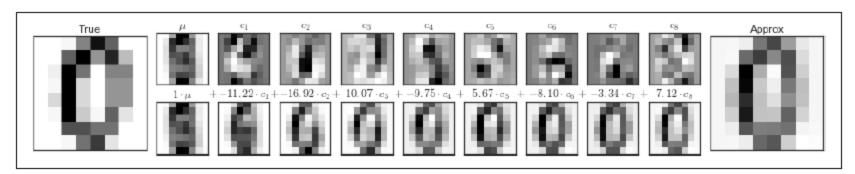
주성분의 의미

■ 원본이미지(64개 변수)의 처음 8개 pixels(기저)을 basis로 하여 8차원으로 표현(projection) 하면 의미없는 이미지를 나타냄



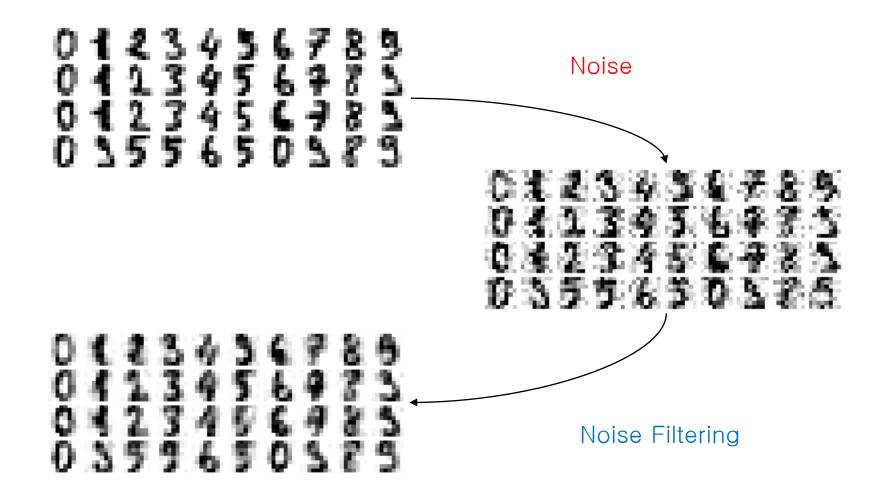
Source: Python Datascience Handbook

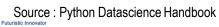
- 단순히 64개 pixel 중에서 임의로 몇 개를 골라 projectio하는 것은 의미가 없음
- 주성분분석을 통해 총변동량을 가장 많이 설명해주는 기저함수(basis functions, PCA basis function)로 구성하여 이미지를 나타내면 원본 이미지와 거의 동일함





PCA as Noise Filtering





경복<mark>대학교</mark> 16 및 빅데이터과 I

PCA as image recognition

■ 고차원 이미지데이터(62 * 47 pixel, 2,914 dimensionality)를 주성분 150개로 인지하여 원래 이미지로 복원

