
제10장. 회귀(回歸, regression)

- 단순/다중 회귀 분석(Simple & Multiple Linear Regression)
- 로지스틱 회귀분석(Logistic Regression)



Study Point


- 데이터, 알고리즘, 모형을 이해하고 scikit-learn 머신 러닝을 이해한다.
- 단순/다중 선형회귀 분석과 로지스틱 회귀 분석을 이해하고 실습한다.
- 이항분류와 다항분류를 이해한다.



머신러닝

컴퓨터에게 데이터에 존재하는 규칙성(regularities)을 발견하게 하여 새로운 데이터의 예측을 컴퓨터가 스스로 하게 하는 것 (사람이 규칙을 찾아서 문제를 해결하는 방법은 이제는 너무 어려움)

Rule based approach






단순 선형 회귀생성

X가 얼만큼 변하면 Y가 어느 정도 변하는지를 추정하기 위해 y = a + bX의 선형식을 가정하고 데 이터를 가장 그럴듯하게 나타내 줄 수 있는 기울기와 절편을 찾는 것이 목적





인공지능 알고리즘 출현 연대기




https://towardsdatascience.com/interpreting-machine-learning-model-70fa49d20af1



데이터, 알고리즘, 모형

머신러닝의 목적은 과거 데이터(data)에 숨어있는 패턴을 학습하여(learn, fit) 예측하는 모형 (model)을 발견하여 새로운 데이터를 예측하는 것






머신러닝 메커니즘(작동방식)

X = [[1,2,3], [11,12,13]]; y=[0,1]


from sklearn.ensemble import RandomForestClassifier
clf = RandomForestClassifier()
clf.fit(X,y)
clf.predict([[4,5,6]])





회귀생성

```
# Target이 실수형 인 자료
from sklearn.datasets import make_regression
X, y = make_regression(n_features=1, noise=10,
                       random_state=111)
import matplotlib.pyplot as plt
plt.scatter(X, y)
```




X(특성변수)가 없다면 y를 예측하는 방법은 평균과 표준편차

y.mean()

bottom = y.mean() - 1.2*y.std()

ceiling = y.mean() + 1.2*y.std()

plt.hist(y) # Histogram plt.axvline(y.mean(), 0, 15, color='orange', linestyle='dotted') plt.axvline(bottom, 0, 15, color='red', linestyle='dotted') plt.axvline(ceiling, 0, 15, color='blue', linestyle='dotted')





회귀생성

```
# 예측 1 (randomforest 회귀생성)
from sklearn.ensemble import RandomForestRegressor
regr_rf = RandomForestRegressor()
regr_rf.fit(X, y)
                                    array([-2.63552691])
regr_rf.predict([[0]])
y_predict_rf = regr_rf.predict(X)
plt.scatter(X, y, label='y_actual')
plt.scatter(X, y_predict_rf, label='y_randomforest regression')
plt.legend()
                                                                   y actual
                                                           100
                                                                   y randomforest regression
                                                            75
                                                            50
                                                            25
```

0

-25

-50

-75




회귀생성

```
# 예측 2 (단순선형회귀분석)
```

from sklearn.linear_model import LinearRegression
regr_Ir = LinearRegression().fit(X, y)
y_predict_Ir = reg_Ir.predict(X)
regr_Ir.predict([[0]])

array([2.08555217])

plt.scatter(X, y, label='y_actual')
plt.scatter(X, y_predict_lr, label='y_linear regression')
plt.legend()





회귀생성 평가 지표


```
# MAE(평균절대오차)
# 실제 값과 예측 값의 차이(Error)를 절대값으로 변환해 평균화
# 이상치가 많을 때
from sklearn.metrics import mean_absolute_error
print('MAE_rf',mean_absolute_error(y, y_predict_rf))
print('MAE_Ir',mean_absolute_error(y, y_predict_Ir))
  MAE rf 3.319178718972687
 MAE Ir 6.864340099043651
# MSE(평균제곱오차)
# 실제 값과 예측 값의 차이를 제곱해 평균화
# 특이값이 존재하면 수치가 많이 늘어나 이상치에 민감하다
from sklearn.metrics import mean_squared_error
print('MSE_rf',mean_squared_error(y, y_predict_rf))
print('MSE_Ir',mean_squared_error(y, y_predict_Ir))
 MSE rf 16.696715708459532
 MSE Ir 71.6356778212634
```




회귀생성 평가 지표_기하학적 의미

$$ext{MAE} = rac{\sum_{i=1}^{n} |y_i - x_i|}{n} = rac{\sum_{i=1}^{n} |e_i|}{n}$$

$$ext{MSE} = rac{1}{n} \sum_{i=1}^n \left(Y_i - \hat{Y_i}
ight)^2$$





회귀생성 시각화


import numpy

예측 1(랜덤포레스트)과 예측 2(선형회귀)의 시각화

x = numpy.linspace(X.min(), X.max(), 60)

y_predict_rf = regr_rf.predict(x.reshape(-1,1))


새로운 X 변수





결정계수(coefficient of determination)


```
# y의 평균과 표준편차로만 예측
plt.scatter(X, y, label='y')
plt.axhline(y.mean(), -2, 2, color='red', linestyle='dotted')
plt.axhline(ceiling, -2, 2, color='black', linestyle='dotted')
plt.axhline(bottom, -2, 2, color='blue', linestyle='dotted')
```






결정계수(coefficient of determination)


- 데이터에 얼마나 Fitting을 잘하였는지 보여주는 성능 지표로 추정한 선형 모형이 주어진 자료에 적합한 정도를 재는 척도
- 결정계수의 값은 0에서 1사이에 있으며, 종속변인(y)과 독립변인(X) 사이에 상관관계(correlation)가 높을수록 1에 가까워짐
- 즉, 결정계수가 0에 가까운 값을 가지는 선형회귀모형은 유용성이 낮은 반면, 결정계수의 값이 클수록 회 귀모형의 유용성이 높다고 할 수 있음






- 단순/다중 회귀 분석(Simple & Multiple Linear Regression)
- 로지스틱 회귀분석(Logistic Regression)










시그모이드 함수


■ 전염병 확산, 기술 확산, 마케팅 구전효과 등 확산 곡선(diffusion curve)형태는 Sigmoid Function 형태를 갖는다.

sigmoid Function
xx = np.linspace(-5, 5, 1000)
plt.plot(xx, 1/(1+np.exp(-xx)), 'r-', label='Sigmoid Function')











신종코로나 바이러스 확산추이 및 감염자 예측을 위한 수학적 모델링

로지스틱 회귀분석

```
from sklearn.datasets import make_blobs import statsmodels.api as sm X, y = make_blobs(100, 1, centers=2, random_state=14, cluster_std=5) # 가상 데이터 y_predict = sm.OLS(y, X).fit().predict(X) # 단순선형 회귀분석 plt.scatter(X[:, 0], y, c=y, cmap='coolwarm') plt.plot(X, y_predict); plt.ylabel('y'); plt.xlabel('X'); plt.show() #로지스틱회귀분석 plt.scatter(X[:, 0], y, c=y, cmap='coolwarm') plt.scatter(X, y_predict); plt.ylabel('g(y)'); plt.xlabel('X');
```








Logistic regression – Iris binary classification


```
from sklearn.datasets import load_iris
iris = load iris()
X = iris.data[:, :2] # 2차원 그림 그리려고 2개 변수만
y = iris.target
# iris 이름이 setosa and versicolor 인 개만 이항분류를 위해
X = X[(y == 0) | (y == 1)]
y = y[(y == 0) | (y == 1)]
plt.scatter(X[:, 0], X[:, 1], c=y, cmap='winter')
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, random_state=0)
from sklearn.linear_model import LogisticRegression
Ir= LogisticRegression(random_state=11, solver='saga')
Ir.fit(X_train, y_train)
Ir.coef
# Sigmoid 함수의 값은 X(100,2)와 회귀식의 계수의 내적
z = X@Ir.coef_.reshape(2,1)
Igr = 1 / (1 + np.exp(-z))
                                         # type(lgr)
```



Logistic regression - Iris binary classification

```
np.sort(lgr.flatten()) # 2차원 그림을 그리기 위해 순서 정열 plt.scatter(np.arange(len(lgr)), np.sort(lgr.flatten()), cmap='winter') plt.scatter(X[:, 0], X[:, 1], c=lgr, cmap='magma') # 채도가 낮을 수록 예측 확률의 값이 낮음
```








Logistic regression – Iris binary classification

```
# 편향(bias)을 발생시키면서 컬럼 1개 추가
                                                                                array([[1. , 5.1, 3.5],
n = X.shape[0]
                                                                                      [1., 4.9, 3.],
                                                                                      [1., 4.7, 3.2],
X_{with\_bias} = np.hstack((np.ones((n, 1)), X))
                                                                                      [1., 4.6, 3.1],
                                                                                      [1., 5., 3.6],
X_with_bias[:10]
                                                                                      [1., 5.4, 3.9],
                                                                                      [1. , 4.6, 3.4],
                                                                                      [1., 5., 3.4],
X_train, X_test, y_train, y_test = train_test_split(X_with_bias, y, random_sta
                                                                                      [1., 4.4, 2.9],
Ir.fit(X_train, y_train)
                                                                                      [1. , 4.9, 3.1]])
Ir.coef
X_with_bias.shape
Ir.coef_.reshape(3,1).shape
z = X_with_bias@Ir.coef_.reshape(3,1)
1/(1 + np.exp(-z))
                                                                       1.0
# 3차원으로 그리기
                                                                       0.8
from mpl_toolkits import mplot3d
                                                                       0.6
plt.figure(figsize=(8,6))
                                                                       0.4
ax = plt.axes(projection='3d')
                                                                       0.2
ax.scatter3D(X[:, 0], X[:,1], 1 / (1 + np.exp(-z)), c=y)
```



ax.view_init(10, 200)



Logistic regression - Titanic binary classification

```
# Logistic regression
import seaborn as sns
df = sns.load_dataset('titanic')
y = df['survived']
X = df.drop(columns= ['pclass', 'who', 'adult_male', 'who', 'adult_male', 'deck', 'embark_town', 'alive',
'alone'])
# 결측치 대체
X.isnull().sum()
X['age'] = X['age'].fillna(X['age'].mean())
X['embarked'] = X['embarked'].fillna(X['embarked'].mode()[0]) # X['embarked'].mode()[0] + str
# dtypes확인하고 변경
X.info()
for col in X.columns[[1, 6]]:
  X[col] = X[col].astype('category')
X.info()
cats = [col for col in X if X[col].dtypes =='category'] # 범주형변수만 cats로 저장
```




Logistic regression - Titanic binary classification

```
# 범주형 변수 Onehot code 변환
X = pd.get_dummies(X, prefix = cats)
X.head()
# 수치형변수 자료 표준화
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
scaler.fit(X[['age', 'fare']])
scaler.transform(X[['age', 'fare']])
X.loc[:, ['age', 'fare']] = scaler.transform(X[['age', 'fare']])
X.head()
# 훈련과 시험데이터 분리후 훈련데이터 학습
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test=train_test_split(X, y, test_size=0.2, stratify= y, random_state=11)
from sklearn.linear_model import LogisticRegression
Ir= LogisticRegression(random_state=11, solver='saga')
Ir.fit(X_train, y_train)
                                      LogisticRegression
                        LogisticRegression(random_state=11, solver='saga')
```



Logistic regression - Titanic binary classification





Logistic regression - MNIST multi class 분류

```
# Logistic regression
from sklearn.datasets import load digits
data = load_digits()
df = pd.DataFrame(data.data, columns=data.feature_names)
df['label'] = data.target # df['label'] = df['label'].apply(lambda x: 0 if x != 1 else x) 이항분류의 경우
X = df.drop('label', axis=1)
X = X/X.max() # 표준화
X.fillna(0, inplace=True)
y = df['label']
X_train, X_test, y_train, y_test=train_test_split(X, y, test_size=0.2, stratify= y, random_state=11)
from sklearn.multiclass import OneVsRestClassifier
base_Ir= LogisticRegression(random_state=11, solver='saga')
# OneVsRestClassifier wrapper. 다중 class 분류 방식
ovr = OneVsRestClassifier(base Ir)
ovr.fit(X_train, y_train)
```



Logistic regression

```
# confusion matrix
%matplotlib inline
y_predict = ovr.predict(X_test)
cm = confusion_matrix(y_test, y_predict, labels=ovr.classes_)
disp = ConfusionMatrixDisplay(confusion_matrix=cm, display_labels=ovr.classes_)
disp.plot()
                                                                                                 35
                                                                                                 30
                                                                                                 - 25
                                               Frue label
                                                                                                 - 20
                                                                        35
                                                                                                - 15
```



26

36

0

Predicted label

- 10